

本地部署开源大模型

Ch.2 智选GPU算力平台：免费与付费租赁指南

上一期内容中我们详细的剖析了如果想本地部署开源大模型，如何去搭配一台合适的个人计算机或者服务器。除此之外，还可以通过租用在线GPU算力，来更灵活的获取计算资源。

GPU云主机租用是一种云计算服务模式，用户可以通过向云服务提供商支付租金，将GPU云主机上的计算资源用于自己的任务中。对于初学者，或仅仅是要做短期项目研究的学生，甚至是探索AI应用落地尝试的企业人员，相较于直接购买高昂的硬件设备和自行搭建计算集群，使用GPU云服务器具有较高的性价比。其一，GPU云服务器具有灵活的配置和租赁方式，可根据实际需求调整计算资源。其次，GPU云服务器提供了高效、稳定、安全的计算环境。总体投入成本是很低的。

市面上提供GPU租赁的平台不少，比如国外的谷歌，vast.ai这种，可以薅资本主义羊毛。因为不花钱，必然多花精力和时间，看各种攻略，想各种办法突破限制。整体看来其实不划算，有那精力还是做点更有意义的事情，毕竟人的自由时间才是最大的财富。而国内的服务商，大厂的比如阿里、金山的都比较贵，相反，现在崛起的平价GPU云服务商。各种类型都有，有自己搭建的民房，有用数字币结算的，还有矿机改的，名字不提了。所以如何选择呢？

各个平台，首先要保证机器的稳定性，其中包括GPU的分布情况，合理的分配机制，被无辜占用的风险或者是一些项目运行急停的预警等等，最怕的就是辛辛苦苦跑了半天结果被中断，功亏一篑！当然价格肯定是影响大家选择的一个很重要的因素！细水长流还是比较重要的，就GPU海量计算而言，阿里云是国内首选。阿里云的GPU云服务器是基于GPU应用的计算服务，最适合AI深度学习、视频处理、科学计算、图形可视化等应用场景。阿里云的GPU服务器支持周、月、年购买，支持批量支付，对于短期需求的用户来说相当方便。但是它确实是太贵。总的来说，在各个机型的价格对比都差不多，选择一个使用舒服的平台还是比较重要，如果你有心思去进行各个平台的活动比价，还是可以有非常多的选择。

本文我们就从两方面：白嫖和付费两方面来剖析目前市场上主流的算力平台。但需要说明的是：对于本地化部署开源大模型的小伙伴来说，免费的GPU资源都不足以支撑起大模型的服务，必须要去根据GPU的显存要求去选择更高配置的机器。

但是，我给大家薅到了一个免费、且支持大模型开发的云计算平台，就是阿里云的人工智能PAI，接下来我们就先来看一下。

一、免费GPU资源推荐


1.1 阿里云人工智能PAI

阿里云人工智能平台 PAI 是面向开发者和企业的AI工程化平台，提供了覆盖数据准备、模型开发、模型训练、模型部署的全流程服务。可以白嫖GPU资源的用户群体是：**阿里云认证用户且为产品的新用户**。有3款支持试用的产品，分别是：

1. 交互式建模 PAI-DSW：深度学习开发环境，集成JupyterLab，支持调试和运行Python代码。支持开源框架的安装，提供了阿里巴巴深度优化的Tensorflow框架；
2. 模型在线服务 PAI-EAS：模型在线服务平台，支持用户将模型一键部署为在线推理服务或AI-Web应用；
3. 机器学习PAI-DLC：深度学习训练平台，提供灵活、稳定、易用和高性能的机器学习训练环境。支持多种算法框架，超大规模分布式深度学习任务运行及自定义算法框架；



- Step 4. 免费试用产品



- Step 5. 选择使用产品

这里我们选择交互式建模 PAI-DSW。



点击试用教程，可以看到PAI-DSW资源支持的示例场景。



该资源支持Langchain的应用，ChatGLM-6B模型的部署等实力场景，并且官方也给了比较详细的应用教程。

阿里云为您提供了一定额度的免费PAI-DSW资源供您试用，您在申请了免费试用资源后可根据本教程指南引导，从易到难地体验PAI-DSW的能力。

教程列表	示例场景	操作难度	预计时长
快速启动Stable Diffusion WebUI	实例创建+模型推理	★	15分钟
基于LangChain的检索知识库问答	应用部署+推理验证	★	30分钟
ChatGLM-6B模型轻量微调推理	数据准备+模型微调+模型推理	★★	45分钟
基于Wav2Lip+TPS-Motion-Model+CodeFormer技术实现动漫风格数字人	准备环境+准备模型+生成动漫风格数字人	★★★	45分钟
AIGC Stable Diffusion文生图Lora模型微调实现虚拟上装	实例创建+模型训练+模型推理	★★★	50分钟
Llama2-7B-Chat大模型的轻量化LoRA微调及量化	数据准备+模型微调+模型推理	★★★	80分钟
基于开源库so-vits-svc生成AI歌手	数据准备+模型训练+离线推理	★★★★	65分钟
AI图片修复	数据准备+模型推理	★★★★	110分钟
基于EasyPhoto的AI写真生成示例 (WebUI版)	数据准备+模型训练+离线推理	★★★★	65分钟

• **Step 6. 选择交互式建模 PAI-DSW，进行试用。**

交互式建模 PAI-DSW资源AI 机器学习；使用 Python 代码进行模型开发的场景，但需要注意的是：从说明上看，开始每日上午08点开始限量领取 500 份，所以如果当日显示无法试用，就说明份额已经被领取完了，需要第二天再来拼手速。

机器学习平台

额度3个月内有效

交互式建模 PAI-DSW

模型开发服务，支持Python代码编写Notebook，内置 JupyterLab、WebIDE 及 Terminal，提供底层 Sudo权限，开放灵活。

5000CU*H 3个月

规格信息：7月5日开始每日上午08点开始限量领取 500 份。
。领取NAS免费包搭配使用，可进行数据持久化存储。
5000CU*H 用量，超出按量计费，支持抵扣DSW开发实例的
A10/V100/G6 3 种机型:ecs.gn7i-c8g1.2xlarge,ecs.gn6v-

试用教程

点这里进行试用

立即试用

试用赠送了5000计算时，相当于10000元的价值，血赚。能选择的机型为 A10，V100和G6，按小时计费，不同机型每小时的费用也不同，做大模型部署的话，建议选择V100，其次是A10。

交互式建模 PAI-DSW

资源包版本: Freetier/活动版

支持抵扣PAI-DSW入门机型计算用品, 抵扣规则:

A100机型 (ecs.gn7-c8g1.2xlarge):	每使用1小时, 消耗6.99计算时
V100机型 (ecs.gn6v-c8g1.2xlarge):	每使用1小时, 消耗14.55计算时
G6机型 (ecs.g6.xlarge):	每使用1小时, 消耗0.57计算时

可选择的机型

容量规格: 5000h计算时

免费赠送的计算时

包类型: DSW中国内地公共云通用

中国内地公共云DSW开服Region通用, 包括北京、上海、杭州、深圳

试用数量: 1

试用时长: 有效期3个月, 过期作废

服务协议: ☐ 我已阅读并同意PAI-DSW资源抵扣服务协议

温馨提示: 以下展示的是试用价格, 试用结束或试用资源用尽后, 需按该商品正常定价购买或使用。

5000h计算时如果购买的话, 需要10000元

应付费用: ¥0.00

立即试用

• Step 7.成功创建实例

点击立即试用后, 如果今日还有免费份额, 即可成功创建实例。

交互式建模 PAI-DSW

世界会展现出新花样, AIGC写真大挑战, 分享创作作品赢惊喜好礼查看更多>

提交成功

交互式建模 PAI-DSW 5000CU*H 3个月 试用服务正在开通中, 请留意短信、邮件等通知

资源类型	包年包月
试用时长	3个月, 试用期间免费, 超过试用期限会自动停机或释放
自动续费	未开启

为避免因试用实例到期停机或释放而影响业务, 请在试用到期前, 及时在用户中心-我的试用中进行购买。

管理试用 前往控制台 查看试用教程

• Step 8.进入控制台

人工智能平台 PAI (原机器学习平台)

人工智能平台 PAI (Platform for AI, 原机器学习平台PAI) 是面向开发者和企业的机器学习/深度学习工程平台, 提供包含数据标注、模型构建、模型训练、模型部署、推理优化在内的AI开发全链路服务, 内置140+种优化算法, 具备丰富的行业场景插件, 为用户提供低门槛、高性能的云原生AI工程化能力。

智算服务 PAI-灵骏新发布公共云Serverless版, 支持AIGC等大规模训练场景

立即开通 管理控制台 免费试用 产品文档 产品定价 Notebook Gallery

• Step 9.开通PAI 并创建默认空间

人工智能平台PAI

阿里云人工智能平台PAI (Platform of Artificial Intelligence), 面向企业客户及开发者, 提供轻量化、高性价比的云原生机器学习平台, 涵盖 PAI-DSW 交互式建模、PAI-Designer 拖拽式可视化建模、PAI-DLC 分布式训练到 PAI-EAS 模型在线部署的全流程, 支持百亿特征、千亿样本规模加速训练, 百余种落地场景, 全面提升机器学习工程效率。了解详情

1 开通 PAI 并创建默认工作空间

数据准备 (PAI-iTag)

高质量数据是提升模型效果的保障, PAI提供智能标注产品PAI-iTag及高效的数据集管理能力。

模型开发 (PAI-DSW / PAI-Designer)

您可以选择可视化建模PAI-Designer或者交互式建模PAI-DSW进行模型设计及开发。

训练及调优 (PAI-DLC)

PAI-DLC分布式训练, 支持大规模高性能计算资源及业界领先的分布式训练框架, 助力降本提效。

模型部署 (PAI-EAS)

PAI-EAS模型在线服务, 您可以将模型部署为一个在线服务或AI-Web应用, 支持大规模复杂模型的一键部署。

• Step 10.进行服务角色授权

1 订单详情

2 开通完成

地址

华东2（上海）

部署区域请参考《PAI部署地域》

PAI产品开通

按量付费

资源消耗按实际使用量付费，计费标准请参考：《PAI计费标准》
如您已在试用中心领取过免费资源包，可自动抵扣对应符合试用规格的资源实例。

组合开通

☐ 当前区域未开通OSS，建议您同时组合开通OSS按量付费，OSS作为AI资产的存储介质，在AI开发过程中被广泛使用，详见：什么是OSS？
计费标准请参考：《OSS按量计费》

☐ 当前区域未开通MaxCompute，建议您同时组合开通MaxCompute按量付费，MaxCompute作为大数据计算存储引擎可以为PAI提供算力与存储介质，详见：什么是MaxCompute？
计费标准请参考：《MaxCompute按量计费标准版》

☐ 当前区域未开通DataWorks，建议您同时组合开通DataWorks基础版，DataWorks可以为PAI提供定时进行训练任务调度的能力，详见：什么是DataWorks？
计费标准请参考：《DataWorks资源消耗计费标准》

工作空间 ③

默认工作空间

为了方便您及账号成员快速在PAI上进行资源AI开发体验：

☒ 将已开通的通用计算资源按量付费公共资源组关联至默认工作空间

☒ 将您全部子账号赋予默认工作空间的算法开发角色

服务角色授权

去授权

为了保障您顺畅的进行AI全链路开发，建议您使用主账号对PAI进行服务授权，避免后续在各个子产品中多次授权。

☒ 我已阅读并同意 《机器学习(PAI)服务协议》《PAI 服务等级协议》《大数据计算服务MaxCompute（按量计费）服务协议》《对象存储OSS服务协议》《DataWorks服务等级协议》《DataWorks产品服务协议》

确认开通并创建默认工作空间

取消

授权页面全部默认选项，点击同意授权即可。

PAI 请求获取访问您云资源的权限

下方是系统创建的可供 PAI 使用的角色，授权后，PAI 拥有对您云资源相应的访问权限。

AliyunPAIDatasetAccDefaultRole 展开详情

同意授权

取消

出现此页面时，表明授权成功。

云资源访问授权成功

Step 11.确认开通并创建默认工作空间

服务角色授权

您已完成授权

为了保障您顺畅的进行AI全链路开发，建议您使用主账号对PAI进行服务授权，避免后续在各个子产品中多次授权。

☒ 我已阅读并同意 《机器学习(PAI)服务协议》《PAI 服务等级协议》《大数据计算服务MaxCompute（按量计费）服务协议》《DataWorks服务等级协议》《DataWorks产品服务协议》


确认开通并创建默认工作空间

取消

Step 12.开通成功后，进入PAI控制台



- Step 13.进入交互式建模 (DSW)



- Step 14.新建一个工作空间

交互式建模 (DSW)

为AI开发者量身定制的云端机器学习交互式开发IDE，随时随地开启Notebook快速读取数据、开发算法、训练及部署模型。



- Step 14.填名称即可，OOS相关内容可以忽略



基础信息

关联资源

新增关联资源

为此工作空间关联所需要的资源

通用计算资源

MaxCompute资源

Flink全托管资源

资源名称	CPU (核数)	内存	GPU (卡数)
☒ public-cluster(公共资源组)	-	-	-

相关模块介绍

如需在工作空间中使用特定模块，请注意勾选支持该模块的资源组。

✓ Designer

封装常用机器学习算法及丰富的可视化组件，您无需代码基础，通过拖拉拽即可训练模型。[查看详情](#)

✓ DSW

为AI开发者量身定制的云原生机器学习交互式开发IDE，随时随地开启Notebook快速读取数据、开发算法、训练及部署模型。[查看详情](#)

✓ DLC (算法训练/容器训练)

算法训练提供了开箱即用的算法，容器训练支持提交自定义代码，均可基于通用训练资源及灵活算资源进行稳定可靠的模型训练。[查看详情](#)

✓ EAS

模型在线服务。[查看详情](#)

创建

• Step 15.创建完成后，进入工作空间

基础信息

关联资源

初始化工作空间

工作空间名称: Cheney
工作空间描述: test

新增关联资源

为此工作空间关联所需要的资源

public-cluster

专有资源组

通用计算资源

进入工作空间

返回概览页

• Step 16.创建DSW实例

Cheney

交互式建模 (DSW)

为AI开发者量身定制的云原生机器学习交互式开发IDE，随时随地开启Notebook快速读取数据、开发算法、训练及部署模型。

创建实例

实例名称

请输入

实例名称	资源配额	可见范围	状态
------	------	------	----

工作空间详情

快速开始 NEW

数据准备

智能标注 (TAG)

特征平台 (FeatureStore)

模型开发与训练

可视化建模 (Designer)

交互式建模 (DSW)

分布式训练 (DLC)

自动机器学习 (AutoML)

模型部署

• Step 17.自行选择GPU规格，不同GPU费用不同，我这里选择V100。

这里能够使用赠送的计算点数的只有三款，V100，A10和G6。根据自己的需求选择。注意：这里要选择支持资源包抵扣的。

CPU规格

GPU规格

部分规格支持通过 PAI-DSW 资源抵扣包 进行抵扣，免费试用实例会自动开启限量关机 功能。入门版资源包限时3折优惠，低至59元。[点击购买](#)

规格名称	CPU	内存 GB	GPU	显存	带宽	价格
ecs.gn5-c2g1.2xlarge 支持资源包抵扣	8 vCPU	32 GB	1 * NVIDIA V100	1 * 16GB	2.5 Gbps	¥ 29.11 /小时 (或14.553计算时/小...)

• Step 18.确认创建实例

现价 (每小时) : 14.55/计算时

当资源包用尽，实例会按照每小时单价 ¥ 29.11 继续收费，实例不使用请及时关闭

下一步

取消

当资源包用尽，实例会按照每小时单价 ¥ 29.11 继续收费，实例不使用请及时关闭

原价（每小时）：14.55 折后价

上一步

创建实例

取消

• Step 19.等待创建完成，需要1~3分钟

实例名称	资源配额	可见范围	状态	优先级	镜像版本	资源类型	服务时长	环境是否保存	操作
test	公共资源组	仅自己可见	环境准备中 闲置关机策略已启用		dsw-registry-vpc-cn-shanghai.c r.aliyuncs.com/pai/modelscop...	GPU	少于1分钟	已保存至云盘	打开 启动 删除 自动停止设置 制作镜像

• Step 20.创建完成后，可以进入运行环境

交互式建模（DSW）

DSW Gallery

为AI开发者量身定制的云端机器学习交互式开发IDE，随时随地开启Notebook快速读取数据，开发算法、训练及部署模型。

创建实例 实例名称 请输入

实例名称	资源配额	可见范围	状态	优先级	镜像版本	资源类型	服务时长	环境是否保存	操作
test	公共资源组	仅自己可见	运行中 闲置关机策略已启用		dsw-registry-vpc-cn-shanghai.c r.aliyuncs.com/pai/modelscop...	GPU	2分	已保存至云盘	打开 停止 删除 自动停止设置 制作镜像

• Step 21.创建Notebook

Notebook

Python 3 (ipykernel)

进入notebook

Console

Python 3 (ipykernel)

Text and terminal

Terminal Text File Markdown File Python File SQL File

Tool

Tensorboard DSW Gallery Show Contextual Help

• Step 22.验证实例配置

```
import subprocess

try:
    subprocess.run("nvidia-smi", shell=True)
except Exception as e:
    print("No NVIDIA GPU found or nvidia-smi is not installed.")
```

Fri Dec 22 16:29:53 2023

NVIDIA-SMI 470.82.01 Driver Version: 470.82.01 CUDA Version: 11.8

GPU Name	Persistence-M	Bus-Id	Disp.A	Volatile Uncorr. ECC
0 Tesla V100-SXM2...	Off	00000000:00:08.0	Off	
N/A	27C	P0 19W / 300W	0MiB / 16160MiB	0%

Processes:

GPU	GI	CI	PID	Type	Process name	GPU Memory Usage
No running processes found						

1.2 阿里天池实验室

阿里天池实验室阿里云提供的打比赛的平台。提供了云端的开发环境，其notebook集成机器学习PAI DSW（DataScienceWorkshop）探索者版，是天池实验室的底座，可以提供完备的IDE以及丰富的计算资源。同时对于任意用户来说，有60个小时的GPU免费使用额度，同时也可以通过在天池内参加比赛、公开notebook、上传数据集等方式活跃账号来获得积分，增加额外的免费时长。

其整体的优点是：国内可直接访问，社区活跃度强，数据集丰富，且开发环境的兼容性非常好。对于GPU的使用，分配资源的方式分为两种：

- GPU独享型：即当前环境下独享GPU资源，但存在的问题就是很多时候会提示没有资源，所以只能碰运气。同时即使获取到了GPU资源，单次使用GPU的时长也不能超过8个小时，会被释放掉；

- GPU共享型：即当前环境下和其他人共享同一个GPU资源，这种情况下基本就无法使用，因为你会发现，当使用这种模型的时候，CPU和Mem都是直接被拉满的。

另外需要注意的是，GPU并不能自主选择，只能让系统随机分配，比如我就分配到 A10, V100, T4等不同的GPU型号。而且有一个小Bug，就是新环境的notebook上传数据后，下次会丢失，好像到目前都没有解决。

但总的来说，阿里的天池实验室可以说是目前用过的非常好用的免费GPU资源。其具体的试用过程如下：


- Step 1.登陆阿里天池官方，进行登陆或者注册：<https://tianchi.aliyun.com/>



- Step 2.登陆后，进入天池实验室的NoteBook



- Step 3.进入后可以看到，有60小时的免费GPU使用



- Step 4.需要进行实名认证




- Step 5.进入我的实验室




- Step 6.创建一个新的NoteBook，如果第一次使用，系统会默认生成一个，也可以直接使用



- Step 7.NoteBook需要点击 编辑 按钮后，进入编辑环境才能进行操作



- Step 8.默认开启的是CPU，如需改为GPU，需要进行切换



- Step 9.最好在执行代码前切换环境，否则需要重新运行全部代码



- Step 10.测试当前环境是否正常加载GPU，可以看到，目前加载的是 NVIDIA 的 A10


```
import subprocess

try:
    subprocess.run("nvidia-smi", shell=True)
except Exception as e:
    print("No NVIDIA GPU found or nvidia-smi is not installed.")
```

Fri Dec 22 10:21:17 2023

NVIDIA-SMI 470.103.01 Driver Version: 470.103.01 CUDA Version: 11.4									
GPU		Name	Persistence-M	Bus-Id	Disp.A	Volatile Uncorr. ECC			
Fan	Temp	Perf	Pwr:Usage/Cap	Memory-Usage		GPU-Util	Compute M.	MIG M.	
0	30C	P8	20W / 150W	00000000:00:08:0	Off	0MiB / 22731MiB	0%	Default	N/A

Processes:

GPU ID	GI ID	CI ID	PID	Type	Process name	GPU Memory Usage
No running processes found						

如果60小时的免费GPU时长全部用尽后，也可以通过积极参加天池的活动、比赛等，较高的活跃度会获得不同数量的积分，达到一定的积分后，阿里天池官方会自动增加免费的GPU使用时长。

我的剩余资源

GPU剩余用量: 60.0小时/60小时
有效期至2023-12-31 23:59:59
积分达200加赠30小时, 点此get升级秘籍

CPU剩余用量: 不限

勋章与积分

认证

我的兑换

开发者社区

Senior Developer	1次Top50	分享1个公开数据集获得5次fork	公开1个notebook获得5次fork或5个star	发表1篇文章获得10个赞
Elite Developer	2次Top10	分享1个公开数据集获得50次fork	公开1个notebook 获得100次fork或30个star	发表1篇文章获得20个赞
Supreme Developer	3次Top1	分享1个公开数据集获得100次fork	公开1个notebook 1000次fork或100个star	发表1篇文章获得50个赞

注: 比赛仅指算法赛、程序设计赛, 排名均指初赛, 即比赛的第一赛季。第一赛季接受后24小时发放。

二. 积分

积分由用户在天池平台产生的行为生成, 体现用户在天池的活跃度。

1. 如何获得积分呢?

行为类型	积分规则
新用户	完善个人信息, 获得50积分
	初赛取得Top 1, 获得200积分
	初赛取得Top 3, 获得100积分
	初赛取得Top 10, 获得50积分

1.3 Kaggle

Kaggle是一个进行数据发掘和预测竞赛的在线平台。从企业的角度来讲, 可以提供一些数据和实际需要解决的问题; 从参赛者的角度来讲, 可以组队参与项目, 针对其中一个问题提出解决方案, 最终由选出的最佳方案获得对应的奖金。Kaggle一直致力于解决业界难题, 因此也创造了一种全新的劳动力市场——不再以学历和工作经验作为唯一的人才评判标准, 而是着眼于个人技能, 为顶尖人才和公司之间搭建了一座桥梁。

作为这样一个大型竞赛平台, 其提供了可以免费访问并可以在云端 GPU 进行深度学习训练的资源和环境。每个用户每周有30个小时的GPU额度。其详细使用过程如下:

- **Step 1. 登录Kaggle官网, 如果是老用户, 可以直接登录。新用户的话先进行注册**



老用户直接登录

新用户先注册

Level up with the largest AI & ML community


Join over 16M+ machine learners to share, stress test, and stay up-to-date on all the latest ML techniques and technologies. Discover a huge repository of community-published models, data & code for your next project.

Register with Google


Register with Email




- Step 2.如果使用Google账号注册，需要挂梯子。如果不想挂梯子或没有梯子，可以选择邮箱注册，QQ邮箱也可以。




- Step 3.登录成功后，需要验证手机号才可以使用免费GPU。



- Step 4.支持中国手机号验证。





Just one thing—first verify your account

Enter your phone number and we'll send you a code

COUNTRY: CN +86 CN

PHONE NUMBER: 100 000 0000

进行人机身份验证

Already have a code? [Enter it now.](#)

Cancel Send verification code


Verifying with a phone number helps us prevent spam and fraud on Kaggle.

- You can only have one Kaggle account. If you have another account, you'll need to first delete that account.
- The phone number needs to be yours, and not a public or shared number.
- Message and data rates apply.

Contact us for help >

Terms and Conditions - Privacy

- Step 5.认证手机号后，新建一个NoteBook。



Kaggle

+ Create

- New Notebook
- New Dataset
- New Competition


Settings

Control over your Kaggle account and all communications

Account Notifications

Your email address

- Step 6.打开NoteBook之后再右侧菜单栏里的 Notebook options——ACCELERATOR 里就可以在几种GPU之间进行选择



Notebook options

ACCELERATOR

None

None


GPU T4 x2

GPU P100

TPU VM v3-8

Pin to original environment

- Step 7.选择GPU。这里我们选择P100。



Accelerator

Turning on GPU P100 will reduce the number of CPUs available and will only speed up image processing and neural networks.

Cancel Turn on GPU P100

Notebook options

ACCELERATOR

None

LANGUAGE

Python

PERSISTENCE

No persistence

ENVIRONMENT

Pin to original environment

- Step 8.环境验证。

```
import subprocess

try:
    subprocess.run("nvidia-smi", shell=True)
except Exception as e:
    print("No NVIDIA GPU found or nvidia-smi is not installed.")
```

Jun Dec 24 03:08:15 2023

NVIDIA-SMI 470.161.03 Driver Version: 470.161.03 CUDA Version: 11.4									
GPU	Name	Persistence-M	Bus-Id	Disp.A	Volatile Uncorr.	ECC			
Fan	Temp	Perf	Pwr:Usage/Cap	Memory-Usage	GPU-Util	Compute M.	MIG M.		
0	Tesla P100-PCIE...	Off	00000000:00:04:0	Off	0%	Default	N/A		
N/A	37C	P0	26W / 250W	0M1B / 16280M1B					

Processes:						
GPU	GI	CI	PID	Type	Process name	GPU Memory
ID	ID	ID				Usage
No running processes found						

+ Code + Markdown

- Step 8.注意：如果安装不上任何包，把页面右侧Setting栏中的Internet选项开启即可正常安装。

LANGUAGE
Python

PERSISTENCE
No persistence

ENVIRONMENT
Pin to original environment

You won't get new packages, but your code is less likely to break. What is a notebook environment? ⓘ

INTERNET
☒ Internet on

TAGS
Add Tags

- Step 9.查看剩余配额情况。

Notebook options

ACCELERATOR
GPU P100
Quota: 00:05 / 30 hrs

LANGUAGE
Python

PERSISTENCE
No persistence

ENVIRONMENT
Pin to original environment

1.4 Colab

Colab是由Google研发的，它免费提供CPU、GPU甚至TPU资源。但是，有一点要注意:要使用你得准备好翻墙的梯子。可以说，大名鼎鼎的谷歌的Colab，全世界都在薅羊毛。历史最久，用户最多，可谓部署界的大佬。谷歌Colab是谷歌打造的深度学习平台，为开发者和研究人员提供免费的云端笔记本运行环境。同时搭载了强大的GPU和TPU计算资源，再搭配一应俱全的深度学习框架和工具，开发者可以直接在上面运行代码或者进行模型训练。


Colab的部署类型属于拎包入住，但分配到的资源都是临时的。分为免费版和收费版，免费版并没有公开具体的配置信息。收费版的Colab Pro每月9.99美金。在选择笔记本时，用户无法选择特定的GPU型号，会自动分配K80, P100, T4, V100等显卡，16G左右的内存，70G左右的存储空间，资源是临时的，每次重启项目时，都需要重新加载，

对于免费用户来说，Notebook最长可以持续运行 12 小时，限额后不知道过多久能重新恢复使用。同时，GPU的类型只能选Tesla T4。除非开通Colab Pro，才能选择更多的GPU资源，但不论是免费用户还是付费用户，限制都很多：

- 实例空间的内存和磁盘都是有限制的，如果模型训练的过程中超过了内存或磁盘的限制，那么程序运行就会中断并报错。实例空间内的文件保存不是永久的，当代码执行程序被断开时，实例空间内的所有资源都会被释放，在"/content"目录下上传的文件也会全部消失；
- 有限的连接时间：笔记本连接到代码执行程序的时长是有限制的，这体现在三个方面：如果关闭浏览器，代码执行程序会在短时间内断开而不是在后台继续执行（这个“短时间”大概在几分钟左右，如果只是切换一下wifi之类的操作不会产生任何影响）；如果空闲状态过长（无互动操作或正在执行的代码块），则会立即断开连接；如果连接时长到达上限（免费用户最长连接12小时），也会立刻断开连接；
- 有限的GPU运行时：无论是免费用户还是colab pro用户，每天所能使用的GPU运行时间都是有限的。到达时间上限后，使用GPU的代码执行程序将被立刻断开且用户将被限制在当天继续使用任何形式的GPU。在这种情况下我们只能等待第二天重置；
- 频繁的互动检测：当一段时间没有检测到活动时，Colab就会进行互动检测，如果长时间不点击人机身份验证，代码执行程序就会断开。此外，如果频繁地断开和连接代码执行程序，也会出现人机身份验证；
- 就算是一直在训练，也会时不时断线，不稳定；

其加载过程如下：

- **Step 1.登录Colab官网（注意：需要挂梯子）** <https://colab.research.google.com/>




- **Step 2.使用Google账号登录**




- Step 3.登陆成功后，新建一个Notebook




- Step 4.连接资源




- Step 5.更改运行环境为GPU



- Step 6.免费用户只能选择T4 GPU




- Step 7.可以看到，已正常加载GPU T4




但需要注意的是，这个分配的资源是临时的（相当于一台没有硬盘的电脑），所以我们还得进行一些操作。即配合Google drive使用。Drive也是免费的。普通Google账号中Drive会有15G的空间。

- Step 8. 挂载Google Driver



- Step 9.账号授权



全部默认选项即可。



点击允许后，命令行终端会生成如下命令。


```
[10] from google.colab import drive


drive.mount('IEEE')

Mounted at IEEE
```


授权成功

此时Colab就用上了Google Drive了。在左边目录可以看到硬盘里面的文件了，把它当做当前的工作环境就可以：







- Step 10.测试安装依赖包



- Step 11.上传文件



而由于需要挂梯子的原因，大文件有时上传很麻烦，熟悉linux命令的同学应该知道wget命令，可以直接使用wget下载，而这里一个小技巧就是：大文件可以先传到百度云盘，然后在百度云盘里生成下载链接嘛（生成那种不需要验证码的）。百度云盘下载很慢但是上传很快。然后再用wget。传文件，服务器与服务器的速度真的超乎本地和服务器的。



分享链接已复制，访问者无需提取码可直接查看分享文件
通过QQ、微信、微博、QQ空间等分享给好友吧

链接:

<https://pan.baidu.com/s/1Ka33puXMJuvWqJFEYAkaw?pwd=7d5y>

链接1天后失效

提取码:

7d5y

复制链接及提取码


二维码:



将二维码分享给好友，
对方微信扫一扫即可获取文件

复制二维码

已含提取码，扫码后无需再次输入



1.5 其他平台

除了上述推荐的平台，还有两个很多人使用的平台，比如移动九天平台：<https://jiutian.10086.cn/edu/#/home>，移动推出的集比赛、数据、训练于一体的平台，貌似不是很活跃，数据集都没多少，但是模型训练的羊毛还是要薅的。通过签到、邀请增加训练时长，按照算例豆来计算，使用过程还可以，但是算力豆消耗的很快。除此之外，百度的AI Studio，是百度提供的一个针对AI学习者的在线一体化开发实训平台，但是V100只能用百度的框架PaddlePaddle，并不是很通用。

二、付费GPU资源推荐

相比于免费平台，付费平台就非常乱了。随着老美的制裁，高端显卡的供不应求，国内超高溢价的情况下，个人、机构由购转租，无疑是一个合适的选择。从而也带动起了显卡租赁厂商的快速增长。这也就导致目前的租赁环境非常乱。首先来看国内大厂如阿里，腾讯，其生态好，行业积累长，但是其对应的GPU实例价格很高，一般个人、学生很难承担的起，更多的是面向企业的采购。而平价的云服务上，鱼龙混杂，生态乱、架构乱、GPU质量难以保障，同时还可能搭着免费的旗号明目张胆的割韭菜。那么在选择平台的时候，如何选择呢？

首先需要明确需求，对于大模型来说，先选择显卡，最低配置是3090；其次是价格，这是很多人关心的一个因素，不同的提供商有不同的计费方式和折扣政策，你需要根据你的预算和使用需求来选择合适的价格方案。而关于配置，这是影响gpu云服务器使用体验的一个重要因素，一般平台都支持灵活扩容，不需要太担心。最后需要关注系统环境，很多系统都比较纯净，对一些依赖如Pytorch不兼容，这对开发人员会造成很大的困扰，尤其对小白不太友好。总体来看，需要保证机器的整体稳定性和开发环境的兼容性。

推荐如下，按先后排名。

2.1 AutoDL

AutoDL刚开始接触这个平台的时候惊艳到我了，和别的租云服务器的平台相比，价格对于学生党来说不要太友好。如果是学生，认证之后直接升级到炼金师三会员等级，可以享受平台最低价。平时活动还超多，代金券领不完的。

• 优惠方案

新用户注册就送炼丹会员，享受9.5折，一个月有效期，这一个月内通过充值提升积分来保持会员，对于学生来说，认证期间一直是会员，非常友好。

• 显卡种类及费用

从1080Ti到A100，共计16种类型的GPU资源，对于大模型来说，我们仅考虑3090及以上级别的资源，各阶段的资费如下：

显卡型号	每小时费用	每天费用	每月费用
RTX 3090	1.58	36.72	805.41
RTX 4090	2.48	53.20	1360.00
A 100 80G	6.68（最便宜）	/	/

• 实际使用情况

1. **可选地域限制**：可选择的服务地域包括西北、北京、芜湖、西南、佛山、内蒙多个区，且每个区的资源都很多；

2. **显卡资源分布**：主流的显卡基本都有资源，相对来说A100 80G短缺；
3. **存储情况**：提供50GB数据盘，不太够用，如果超出按照0.0066/元/日/GB付费；
4. **系统环境**：可选择平台预测环境，也可以选择社区环境，且系统的依赖包预选安装了很多，整体环境对用户比较友好；
5. **开发环境**：只能SSH连接，同时提供云端的运行环境；

具体的使用过程如下：

- **Step 1.进入官网**：<https://www.autodl.com/home>



- **Step 2.老用户可以直接登陆，新用户需要注册**

- **Step 3.登录后，需要认证相关信息，才可以进行GPU的租赁**



账号安全

登录密码

安全性高的密码可以使账号更安全。建议您定期更换密码。设置一个包含字母和数字且长度超过8位的密码

已设置 | 修改

手机绑定

您已绑定了手机130****6660您的手机号可以直接用于登录、找回密码等

已绑定 | 修改

实名认证

实名认证后可以使用AutoDL更完整的功能。如打开实例的自定义服务等

未认证 | 立即认证

微信绑定

绑定微信可快速扫码登录

未绑定 | 绑定

需要全部认证后才可以租用GPU服务器

- Step 4.认证完成后，进行充值，AutoDL对于新用户，目前也没有体验金活动

到期释放预警 已开启 发送记录

余额预警 已开启 (余额不足0元预警)

文件存储
付费容量
0GB

炼丹师6660 个人认证
炼丹会员 (30天后到期)
认证学生升级炼丹会员
等级与会员福利
成长值 20 / 500
距离升级还需480成长值 升级攻略
进入成长值主页>

费用信息
我的余额
¥0.00
充值
代金券 ¥0.00
优惠券 暂无
授信 暂无

- Step 5.充值方式支持微信支付、支付宝和对公汇款

账户余额: ¥0.00

充值金额: ¥50 成长值+50 ¥100 成长值+100 ¥500 成长值+500 ¥1000 成长值+1000 ¥2000 成长值+2000 其他金额

了解会员成长值>>

1.00 ¥ 成长值+1

支付方式: 微信支付 支付宝 对公汇款

如何开票发票? 如何对公汇款?

充值

- Step 6.在进行实例创建前，如果不知道如何选择GPU，还可以在官网首页参考下GPU的算力排名

GPU算力排名				
仅以AutoDL平台提供的加速卡型号进行算力排名，其中NVIDIA GPU以Peak FP16 Tensor TFLOPS with FP32 Accumulate值为半精算力值				
半精算力排名			单精算力排名	
排名	GPU	半精算力	算力	
1	NVIDIA A100 SXM4 / 80GB	100%	312	Tensor TFLOPS
2	NVIDIA RTX 4090 / 24GB	53%	165.2	Tensor TFLOPS
3	NVIDIA A40 / 48GB	48%	149.7	Tensor TFLOPS
4	NVIDIA V100 / 32GB	40%	125	Tensor TFLOPS
5	NVIDIA RTX A5000 / 24GB	38%	117	Tensor TFLOPS

GPU算力排名				
仅以AutoDL平台提供的加速卡型号进行算力排名，其中NVIDIA GPU以Peak FP16 Tensor TFLOPS with FP32 Accumulate值为半精算力值				
半精算力排名		单精算力排名		
排名	GPU	单精算力	算力	
1	NVIDIA RTX 4090 / 24GB		100%	82.58 TFLOPS
2	NVIDIA RTX 3090 Ti / 24GB		48%	40 TFLOPS
3	NVIDIA A40 / 48GB		45%	37.42 TFLOPS
4	NVIDIA RTX 3090 / 24GB		43%	35.58 TFLOPS
5	NVIDIA RTX 3080 Ti / 12GB		41%	34.1 TFLOPS

- Step 7.在算力市场，可以选择GPU资源

算力市场 AI服务圈 算法社区 私有云 帮助文档 更多 控制台

① 严禁使用WebUI等算法生成违禁图片、严禁挖矿，一经发现立即封号！

创建服务器

计费方式: 按量计费 包日 包周 包月

选择地区: 西北B区 北京A区 芜湖区 西南A区 佛山区 西北A区 内蒙A区 北京C区

GPU型号: ☐ 全部 ☐ RTX 4090 (104/2632) ☐ RTX 3080 Ti (7/392) ☐ L40 (尝鲜活动) (0/9) ☐ RTX 3080x2 (0/8) ☐ RTX A4000 (0/24) ☐ RTX 3060 (0/32) ☐ GTX 1080 Ti (0/14) ☐ CPU (0/12)

GPU数量: 1 2 3 4 5 6 7 8 10 12

我们选择一个2080Ti来尝试一下。（为什么不选规格更高的，因为账户的钱不够）

RTX 2080 Ti 北京A区 / 258机 可租用至: 2024-02-05

GPU数量(卡): 1 / 8 CPU: 12 核/GPU, Xeon(R) Platinum 8255C 内存: 43 GB/GPU

显存: 11 GB 系统盘: 30 GB 数据盘: 免费 50 GB, 可扩展 4367 GB 支持最高CUDA版本: 12.2

浮点算力: 单精 13.45 TFLOPS / 半精 53.8 Tensor TFLOPS

¥0.88/时 会员最低享9.5折 ¥0.88/时 1卡可租

这里选择周期和地域，不同地域下的可用GPU资源不同。

计费方式: 按量计费 包日 包周 包月 选择租用周期，时间越长越划算

选择地区: 西北B区 北京A区 芜湖区 西南A区 佛山区 西北A区 内蒙A区 北京C区 不同地区的当前可用GPU资源不同 如没有GPU资源，可切换地区

GPU型号: ☐ 全部 ☐ RTX 4090 (104/2632) ☐ RTX 3080 Ti (7/392) ☐ L40 (尝鲜活动) (0/9) ☐ RTX 3080x2 (0/8) ☐ RTX A4000 (0/24) ☐ RTX 3060 (0/32) ☐ GTX 1080 Ti (0/14) ☐ CPU (0/12)

GPU数量: 1 2 3 4 5 6 7 8 10 12

在选择镜像的时候，这里非常好的一点是可以直接拉去社区镜像。比如我们想部署ChatGLM3，就可以直接在Github上选择一个镜像来安装。

镜像: 基础镜像 社区镜像 hot 我的镜像 社区镜像是什么?

试试搜索Github项目名称，如: YOLOv5, mmDetection。即刻拥有创建即用的算法运行环境

严禁使用WebUI等算法生成违禁图片，一经发现立即封号！

THUDM/ChatGLM-6B/THUDM_ChatGLM-6B-v2 这里非常好，可以选择社区镜像。 比如想部署ChatGLM3，就可以选择一个镜像来安装

创建完成后仍然可以更换其他镜像

比如我们想部署ChatGLM3，就可以直接在Github上选择一个镜像来安装。

THUDM/ChatGLM-6B/THUDM_ChatGLM-6B:v2	tabchen
ChatGLM-6B 仓库的一键脚本 框架: PyTorch:1.11.0 CUDA版本: 11.3 镜像大小: 13.19GB	1.4k 2023-03-15 10:56:34
Akegarasu/ChatGLM-webui/ChatGLM-webui:v1	akibanazu
ChatGLM webui 框架: PyTorch:1.12.1 CUDA版本: 11.3 镜像大小: 18.50GB	838 2023-03-16 00:59:30
THUDM/ChatGLM-6B/ChatGLM-6B_3_in_1:v1	LegnaW
暂无描述 框架: PyTorch:1.11.0 CUDA版本: 11.3 镜像大小: 12.33GB	3 2023-03-16 03:45:52
THUDM/ChatGLM-6B/ChatGLM-6B_3_in_1:v2	LegnaW
暂无描述 框架: PyTorch:1.11 CUDA版本: 11.3 镜像大小: 13.93GB	445 2023-03-16 21:00:50
THUDM/ChatGLM-6B/ChatGLM:v1	SeASn...
封装了ChatGLM及所需依赖,内置了ChatGLM所需的模型文件,创建后即可开箱使用,国产ChatGPT... 框架: PyTorch:1.13.1 CUDA版本: 11.7 镜像大小: 18.12GB	261 2023-03-20 11:01:00
THUDM/ChatGLM-6B/CHATGLM-6B:v1	shao1995
1. 清华的对话模型chatglm-6b https://chatglm.cn/blog; 2. 模型已打包在镜像中,可直接运行; 3. 请... 框架: Miniconda:conda3 CUDA版本: 11.8 镜像大小: 26.16GB	54 2023-03-25 20:51:36
THUDM/ChatGLM-6B/CHATGLM-6B:v2	shao1995

提交订单，开始创建实例。

优惠券:

请选择

日常费用: ¥0.00/日

配置费用: ¥0.88/时

费用明细

取消

立即创建

账户余额: ¥1.00

这里会显示创建过程，一般需要等到 3 min 以上。

实例ID / 名称	状态	规格详情	本地磁盘	健康状态	付费方式	释放时间/停机时间	SSH登录	快捷工具	操作
北京A区 / 120机 f4cd11ad52-f19d79d1 设置名称	创建中 90.20%	RTX 2080 Ti * 1卡 查看详情	系统盘 0% 数据盘 0%	● 正常	按量计费 余额不足24小时	14天23小时59分后释放 设置定时关机			关机 更多


创建完成后，可以通过远程ssh工具连接 或者 AutoDL提供的云端运行环境。

实例ID / 名称	状态	规格详情	本地磁盘	健康状态	付费方式	释放时间/停机时间	SSH登录	快捷工具	操作
北京A区 / 120机 f4cd11ad52-f19d79d1 设置名称	● 运行中	RTX 2080 Ti * 1卡 查看详情	系统盘 26.79% 数据盘 0.00%	● 正常	按量计费 余额不足24小时	关机15天后释放 设置定时关机	登录指令 ssh***** 密码 *****	JupyterLab AutoPanel 实例监控 自定义服务	关机 更多


- Step 8. 这里我们选择在云端的Jupyter lab运行

付费方式	释放时间/停机时间	SSH登录	快捷工具	操作
按量计费 余额不足24小时	关机15天后释放 设置定时关机	登录指令 ssh***** 密码 *****	JupyterLab AutoPanel 实例监控 自定义服务	关机 更多

可以看到，由于我们选择了ChatGLM的镜像环境，在初始化机器的时候已经帮我们创建好了，这能省去我们非常多的时间。



• Step 9.测试GPU资源



• Step 10.如果不用，释放掉资源，避免产生额外的费用



• Step 11.如何白嫖？

首先，如果是学生，一定要去做学生认证，可以一直享受9.5折会员价。

- 注册即送炼丹会员，有效期1个月
 - 认证学生升级炼丹会员，[去认证>>](#)
- 优惠政策，学生更适合

等级	普通用户	炼丹会员
会员条件(非学生)	近3月成长值>=0	近3月成长值>=500
会员条件(学生)	无	认证学生期间一直为炼丹会员

成长值获得规则:

- 每充值1元获成长值
- 即将上线更多任务获取成长值

炼丹会员			普通用户
会员价格 租赁GPU 低于 普通用户			
NVIDIA A100 SXM4 / 80GB 单精 19.5 TFLOPS / 半精 312 Tensor TFLOPS ¥6.68 / 时 会员95折	NVIDIA RTX 4090 / 24GB 单精 82.58 TFLOPS / 半精 165.2 Tensor TFLOPS ¥2.68 / 时 会员95折	NVIDIA A40 / 48GB 单精 37.42 TFLOPS / 半精 149.7 Tensor TFLOPS ¥2.68 / 时 会员95折	
NVIDIA V100 / 32GB 单精 15.7 TFLOPS / 半精 125 Tensor TFLOPS ¥2.28 / 时 会员95折	NVIDIA RTX 3090 / 24GB 单精 35.58 TFLOPS / 半精 71 Tensor TFLOPS ¥1.58 / 时 会员95折	NVIDIA RTX A5000 / 24GB 单精 27.77 TFLOPS / 半精 117 Tensor TFLOPS ¥1.23 / 时 会员95折	

其次，AutoDL经常会搞活动，发放优惠券和代金券，可以常关注一下。

AutoDL帮助文档

- 学术资源加速
- 如何选择GPU
- 容器实例
- 数据
- 配置环境
- 企业高级功能
- 最佳实践
- 网络
- AI服务器
- 常见问题
- 活动
- 代金券
- 优惠券
- 炼丹会员
- 学生认证

领取

入口在首页右侧 -> 领优惠券

在领取优惠券时请确认优惠券的使用范围，一般有：全场通用、部分地区可用、部分主机可用，选择适用于自己的优惠券进行领取。



2.2 Gpushare Cloud

Gpushare Cloud，即恒源云，和AutoDL是目前市场是最大的两家。

• 优惠活动

新用户注册送50元优惠券，但是前提是要完成全部的新手任务才会给，其中就包含首冲30元的任务。所以直接白嫖测试，是没有什么机会的。

学生认证，通过消费提升会员等级，学生的充值金额较少，如果要到黄金会员级别，学生账号仅需充值600，而非学生账号充值30000。

会员权益				
专享权益	普通用户	青铜会员	白银会员	黄金会员
实例消费折扣	-	93 折	9 折	85 折
数据存储折扣	-	93 折	9 折	85 折
课程购买折扣	-	93 折	9 折	85 折
每月代金券	-	每月 10 元	每月 30 元	每月 80 元
无卡启动实例	-	✔	✔	✔
按量付费最大实例数	1~3	3	4	5
每月开票次数	1	1	1	不限
公共数据集下载	✔	✔	✔	✔
团队长功能	-	-	-	✔

• 显卡种类及费用

从2060s到A100，共计31种类型的GPU资源，对于大模型来说，我们仅考虑3090及以上级别的资源，各阶段的资费如下：


显卡型号	每小时费用	每天费用	每月费用
RTX 3090	1.29 （最便宜）	30.03 （最便宜）	835.92 （最便宜）
RTX 4090	2.6	59.28 （最便宜）	1591.20 （最便宜）
A 100 80G	/	/	/

• 实际使用情况

- 1. **可选地域限制**：可选择的服务地域包括华东、华中、东北、西北、华南和西南多个区，且每个区的资源都很多；
- 2. **显卡资源分布**：主流的显卡基本都有资源，相对来说A100 80G短缺；
- 3. **存储情况**：提供50GB数据盘，不太够用，如果超出按照0.0004/GB付费；
- 4. **系统环境**：可选择平台预设环境，同时提供镜像市场，但需要占用个人存储空间；
- 5. **开发环境**：支持远程工具连接，同时也提供云端的运行环境

具体的使用过程如下：

- Step 1.进入官网：<https://www.gpushare.com/>



- Step 2.新用户先注册

注册恒源智享云账号

+86 130 4440000

.....

2 × 4 = 8

180000 重新发送(30s)

☒ 我已阅读并同意 [恒源智享云服务协议](#)

注册

[已有账号，点击登录 >](#)

- Step 3.新用户注册后，可以领取50元的代金券，但比较坑的是，必须做完全部新手任务才能一次性领取，其中就包含首冲30任务

✓ 注册成功


恭喜您注册成功，快来领取新人大礼包吧！

[去控制台](#) **领取礼包**

¥ 15 首充30元
新手任务礼包 充30送15，新人专享 [去做任务](#)

¥ 20 注册礼包
新人任务礼包 包天/周/月优惠券 **已完成**

- Step 4.所以在创建实例之前，需要先进行充值



同样，支持支付宝、微信和对公转账三种方式。



• Step 5.充值成功后，创建实例



支持的GPU类型非常多，从2060 ~ A800共计31种GPU显卡类型。



这里提供镜像市场，但需要占用个人的存储空间，超出后需要按照0.0004/GB付费。



选择完成后创建实例。



等待创建完成，这里显示资源的创建进度。




- Step 5. Gpushare cloud 提供了远程工具连接和云端的运行环境。



这里我们选择直接使用Jupyter lab运行



使用过程与本地Jupyter lab一致。



- Step 6.验证GPU环境

```
import subprocess

try:
    subprocess.run("nvidia-smi", shell=True)
except Exception as e:
    print("No NVIDIA GPU found or nvidia-smi is not installed.")
```

Mon Dec 25 09:06:56 2023

NVIDIA-SMI 525.116.03 Driver Version: 525.116.03 CUDA Version: 12.0									
GPU	Name	Persistence-M	Bus-Id	Disp.A	Volatile Uncorr. ECC	GPU-Util	Compute M.	MIG M.	
Fan	Temp	Perf	Pwr:Usage/Cap	Memory-Usage	GPU-Util	Compute M.	MIG M.		
0	NVIDIA GeForce ...	Off	00000000:22:00:0	Off	0%	Default	N/A		
0%	33C	P8	26W / 330W	0MiB / 24576MiB	0%	Default	N/A		

Processes:


GPU	GI	CI	PID	Type	Process name	GPU Memory Usage
ID	ID	ID				
No running processes found						

- Step 7.释放资源



- Step 8.如何白嫖?

首先，如果是学生的话，一定要做学生认证。



其次，还是老套路，邀请人给自己增加现金奖励。



2.3 Featurize

Featurize也是一个比较好用的平台，主要内置了很多比赛和公开的数据集，属于比较受高校实验室青睐的，之前一直以价格为优势，但现在从各大平台上比较来看，已然成了最贵的。

- 优惠方案

靠充值提升会员等级，最高充值20000元，获取8折优惠，同时充值的时候也会有代金券。

- 显卡种类及费用

从1080Ti到A6000，共计9种类型的GPU资源，对于大模型来说，如果仅考虑3090及以上级别的资源各阶段的资费如下：

显卡型号	每小时费用	每天费用	每月费用
RTX 3090	2.49	55（最贵）	1500（最贵）
RTX 4090	2.78	63（最贵）	1700（最贵）

显卡型号	每小时费用	每天费用	每月费用
A 100 80G	/	/	/

- **实际使用情况**

1. **可选地域限制**：不可选
2. **显卡资源分布**：支持的显卡基本都能找到资源
3. **存储情况**：不同机型，配备的内存和硬盘空间都不同，且不可选择
4. **系统环境**：选择平台预设环境，只有Pytorch和SD环境
5. **开发环境**：支持VScode、Pycharm等IDE远程连接，并提供详细的教程，同时也提供云端的环境

具体的使用过程如下：

- **Step 1.进入官网**：<https://featurize.cn/>



其显卡以高性价比著称，但就目前的平台比价来看，其价格并不占优势。

高性价比的选择

RTX 2080 Ti

长期租用最低

¥ 1.2 / 小时

按量使用 ¥ 2 / 小时

6 核 Xeon(R) CPU E5-2680 v4
32GB 高速内存

开始使用

RTX 3090

长期租用最低

¥ 2.1 / 小时

按量使用 ¥ 3.6 / 小时


8 核 Xeon(R) Gold 6142 CPU
64GB 高速内存

开始使用

- **Step 2.进入控制台**




- **Step 3.进行登陆/注册**



- Step 4.目前只支持微信扫码登录



- Step 5.目前该平台没有任何活动，如果需要创建实例，需要自行充值测试



- Step 6.主页上直接进行GPU资源的选择，这里我们可以看到，目前支持1080Ti到A6000共计9种GPU资源类型



- Step 7.创建实例，这里选择3080进行尝试



这里能显示服务器的详细信息。



执行完创建后，可以查看资源创建的进度。一般来说需要3min以上。



• Step 8.远程连接

Featurize 提供了本地远程工具连接和云端云端运行环境两种，并且给出了详细的教程。



比如想通过Pycharm连接的话。

RTX 30801.41元 / 小时运行中

GPU

1 块 RTX 3080, 共 10.5 GB 显存

CPU

6 核 Xeon Gold 6142

内存

27.1 GB

硬盘

401.0 GB

租用时间

2023-12-25 16:02

租用方式

按量使用

费用情况

共计 0.0 元, 其中代金券已抵扣 0.0 元

到期时间

当前余额预计还可使用 2 小时

Docker

v20.10.10

Python

v3.10.12

PyTorch

v2.0.1

TensorFlow

v2.13.0

打开工作区

强制重启

转长租

退还实例

SSH 连接

用 VS Code 打开

PyCharm 远程连接

操作系统:

Windows 10macOSUbuntu

开发软件:

Visual Studio CodePyCharm

实例 ID: 9164006b-1931-4071-915b-32093d6b5456

在 Windows 10 中使用 PyCharm 远程调试

注意: 本文档针对 Windows 10 操作系统, Windows 7 并不适用; PyCharm 免费版不提供远程运行/调试功能, 请使用 PyCharm 付费版或教育版。

操作文档比较详细, 按照步骤进行安装就行

1. 安装 OpenSSH

Windows 10 系统需要首先安装 SSH 客户端才能进行连接:

以管理员身份运行 PowerShell, 你可以通过左下方的搜索框中直接搜索 PowerShell 即可, 然后右键选择「已管理员身份运行」, 在弹出的终端中依次输入并执行以下命令:

Get-WindowsCapability -Online | ? Name -like 'OpenSSH*'

Add-WindowsCapability -Online -Name OpenSSH.Client~~~~0.0.1.0

2. 选择远程 Python 解释器

首先, 使用 PyCharm 打开你希望调试的某个本地项目, 打开后按 **ctrl + ,**, 弹出偏好设置。然后依次进入 **Project: <project name> -> Python Interpreter**, 点击右侧的 **+** 按钮, 选择 **add**。

miniterorch - setup.py

Python 3

Preferences

使用云端运行环境连接, 就更加简便。

RTX 30801.41元 / 小时运行中

GPU

1 块 RTX 3080, 共 10.5 GB 显存

CPU

6 核 Xeon Gold 6142

内存

27.1 GB

硬盘

401.0 GB

租用时间

2023-12-25 16:34

租用方式

按量使用

费用情况

共计 0.0 元, 其中代金券已抵扣 0.0 元

到期时间

当前余额预计还可使用 2 小时

Docker

v20.10.10

Python

v3.10.12

PyTorch

v2.0.1

TensorFlow

v2.13.0

打开工作区

强制重启

转长租

退还实例

File

Edit

View

Run

Kernel

Tabs

Settings

Help

Filter files by name

work

3 分钟前

Launcher

Notebook

Python 3 (pykernel)

Featurize

添加数据集

SSH 连接

IDE 远程调试

向博主提问

实例 ID: 8719a35b-edf0-4505-8b51-479d7a096349

• Step 9.使用本地工具Xshell测试连接

RTX 30801.41元 / 小时运行中

GPU

1 块 RTX 3080, 共 10.5 GB 显存

CPU

6 核 Xeon Gold 6142

内存

27.1 GB

硬盘

401.0 GB

租用时间

2023-12-25 16:02

租用方式

按量使用

费用情况

共计 0.0 元, 其中代金券已抵扣 0.0 元

到期时间

当前余额预计还可使用 2 小时

Docker

v20.10.10

Python

v3.10.12

PyTorch

v2.0.1

TensorFlow

v2.13.0

打开工作区

强制重启

转长租

退还实例

SSH 连接


用 VS Code 打开

PyCharm 远程连接


实例 ID: 9164006b-1931-4071-915b-32093d6b5456

这里我们先使用本地的Xshell进行远程连接测试

直接复制官方给出的命令至Xshell的终端。




需要修改一下，去掉命令行的-p，否则会报错。



看到此页面，说明远程连接服务器成功，可以在此环境下进行相关的操作。



• Step 10.查看GPU资源



• Step 11.释放资源

RTX 3080

1.41 元 / 小时

运行中

GPU

1 块 RTX 3080, 共 10.5 GB 显存

CPU

6 核 Xeon Gold 6142

内存

27.1 GB

硬盘

401.0 GB

租用时间

2023-12-25 16:02

租用方式

按量使用

费用情况

共计 0.0 元, 其中代金券已抵扣 0.0 元

到期时间

当前余额预计还可使用 2 小时

Docker

v20.10.10

Python

v3.10.12

PyTorch

v2.0.1

TensorFlow

v2.13.0

实例 ID: 9164006b-1931-4071-915b-32093d6b5456

打开工作区

强制重启

转长租

退还实例

Step 12.如何白嫖？

还是老套路，邀请别人自己得奖励。

个人中心

账户信息

福利中心

安全设置

通知设置

会员等级福利

带新奖励

我的带新

带新链接

https://featurize.cn?s=507905e70af2474a9e73138b0422143c

带新数据

当前共带新 0 人, 总计获得代金券 0 元, 目前每带新一人可获得 10 元代金券

规则说明

用户成功邀请新用户注册并完成一笔额度大于 50 元的充值, 我们将赠予老用户一定额度的代金券奖励。邀请的方式只需将带新链接发送给其他人即可, 通过的用户都算为带新用户。奖励的额度与累积带新人数有关, 具体如下:

带新人数	单个带新奖励
累计邀请人数 10 人以内 (包含10人)	每个带新奖励 10 元代金券
累计邀请人数超过 10 人	每个带新奖励 15 元代金券
累计邀请人数超过 30 人	每个带新奖励 20 元代金券

2.4 AnyGPU

AnyGPU主要服务AI深度学习、高性能计算、渲染测绘、云游戏等领域。

优惠方案

首次充值返现优惠：首次充值即享受 15% 的返现优惠。充值的金额越多，获得的返现也越多。例如，若充值 575 元，实际只需支付 500 元。

会员专享折扣：成为会员后，享受所有服务 8.8 折优惠。要成为会员，需要联系客服，并支付 88 元的会员费。相当于是一种“免费送”的优惠，因为会员所享受的折扣将覆盖这笔费用。

显卡种类及费用

从2080Ti到A100，共计12种类型的GPU资源，对于大模型来说，我们仅考虑3090及以上级别的资源，各阶段的资费如下：（目前仅支持按量付费，也就是小时。）

显卡型号	每小时费用	每天费用	每月费用
RTX 3090	1.33	32.00	800.00
RTX 4090	2.27	54.40	1360.00
A 100 80G	7.22	165.44	4180.00

实际使用情况

1. **可选地域限制**：可选择的服务地域包括福州、广州、北京和上海四个地域。但是北京和上海的资源基本创建不到
2. **显卡资源分布**：目前较为充足的显卡资源主要集中在 GeForce RTX 2080Ti、3080 和 3090，RTX 4090 和 A 系列显卡基本没有，而且尽管系统上显示资源存在，实际上在创建过程中经常出现报错，导致无法成功创建实例。
3. **存储和系统环境**：提供 200GB 的数据盘，通常足够使用。但系统环境只能选择平台预设的选项，不支持自定义镜像。并且操作仅能通过 SSH 远程工具完成，不提供云端运行环境。
4. **系统环境纯净但对新手不友好**：系统环境较为“纯净”，许多必要的依赖包并未预装，这对于初学者来说可能不太友好，需要自行配置和安装所需软件。

具体的使用过程如下：

- **Step 1. 进入官网**：<https://www.anygpu.cn/>



- **Step 2. 新用户先进行账户注册**



- **Step 3. 首次注册，关注公众号可以获得10元体验金，可用于租赁服务器**



账号

赠送的10元体验金，立即到账

- Step 4. 同时，参加问卷调查，可以额外获得10 ~ 50体验金，5~10个工作日到账

方式一：点击下方图标参与问卷调查



方式二：关注本公众号“算力云”并发送关键词“问卷调查”参与活动~



- Step 5. 注册完成后进入控制台




- Step 6. 这里可以看一下，该平台会员是8.8折优惠



我也咨询了一下客服，是需要充值88元到账户中，会给开通会员。其实也算白送一个月会员。




同时，也有一个首冲福利。充的越多，越划算。



- Step 7. 目前该平台支持从2080Ti到A100共计12种类型的GPU资源



- Step 8. 在创建实例前，建议完善一下账号信息，毕竟涉及财产安全



绑定手机号。



- Step 9. 完善账号信息后，创建实例



这里可以切换地域，不同地域下可创建的资源不同。



选择具体的GPU资源，同时还有免费200GB的数据盘。

显卡数量: 1 2 3 4

算力池:

RTX 3080

¥0.88/小时

GPU RTX 3080 10GB显存

CPU 8核

内存 48G

系统盘 50G

数据盘 免费200G

浮点算力 单槽 29.77 TFLOPS

RTX 3090

¥1.52/小时

GPU RTX 3090 24GB显存

CPU 8核

内存 48G

系统盘 50G

数据盘 免费200G

浮点算力 单槽 35.58 TFLOPS / 半槽 71 Tensor TFLOPS

RTX 2080Ti

¥0.70/小时

GPU RTX 2080Ti 11GB显存

CPU 8核

内存 48G

系统盘 50G

数据盘 免费200G

浮点算力 单槽 13.45 TFLOPS / 半槽 26.90 Tensor TFLOPS

RTX 4090

¥2.58/小时

GPU RTX 4090 24GB显存

CPU 8核

内存 48G

系统盘 50G

数据盘 免费200G

浮点算力 单槽 82.58 TFLOPS / 半槽 165.2 Tensor TFLOPS

数据盘: - 200 +

数据盘免费 200 GB, 扩容部分按官网价格收取费用, 生命周期跟随实例

这里我们选择3090试一下

只能选择系统提供的镜像。在这里选择操作系统。

镜像类型: 系统镜像 我的镜像

系统镜像包含常用的基本软件, 如: Miniconda, PyTorch等, 如需其他软件可创建后安装。

镜像:

Ubuntu
Ubuntu/20.04.3

Window 10 x64

TensorRT

PaddlePaddle

PyTorch

Miniconda

Jittor

TensorFlow

JAX

只能选择系统提供的镜像。在这里选择操作系统。

配置:

RTX 3090 24GB * 1

8核 / 48GB

系统盘 50GB, 数据盘 200GB

镜像 Ubuntu/20.04.3

¥1.52/小时

可用余额: ¥10.00 去充值

创建实例

地域: 福州八区

计费方式: 按量付费

实例	RTX 3090 24GB * 1 AMD EPYC 7542 8 vCPU / 48GB 系统盘 50 GB	¥1.52/小时
数据盘	200GB 本地盘	¥0.00/小时

应付费用: ¥1.52/小时

提交订单

• Step 10. 提交订单后等待创建完成

关注公众号, 及时了解最新优惠活动, 首次充值还可额外获得15%的赠送福利

ecs-q00000079hwx 创建中!

例 注意: 账户欠费显卡将会被回收, 欠费48小时或实例连续关机7天将会被释放(数据未释放前会保留)。显卡紧缺, 请保持账户余额充足。 查看更多规则

请输入实例名称 实例名称 C 提示: 若长时间无法连接, 可强制关机后再次开机启动实例

+ 创建

实例ID / 名称	地域	规格	磁盘	付费方式	状态	连接方式	操作
ecs-q00000079hwx 20231225111536649533	福州八区(可用区A)	RTX 3090 24GB * 1 8核 / 48GB	系统盘: 50 GB	按量付费	进行中	SSH连接	详情 ...

有个问题是: 尽管资源显示充足, 但是经常性创建失败, 我这里3090一直无法创建, 所以最终创建一台3080.




- Step 11. 该平台目前只能SSH远程连接，并没有提供云端运行环境



点击 SSH 连接，可以查看相关的远程连接信息。



- Step 12. 使用Xshell远程工具连接服务器



输入用户名和密码。


```
root@iofuwqan:~# nvidia-smi
Mon Dec 25 11:49:00 2023

+-----+
| NVIDIA-SMI 525.147.05   Driver Version: 525.147.05   CUDA Version: 12.0   |
+-----+-----+
| GPU  Name            Persistence-M| Bus-Id        Disp.A | Volatile Uncorr. ECC |
| Fan  Temp  Perf    Pwr:Usage/Cap|      Memory-Usage | GPU-Util  Compute M. |
|-----+-----+-----+
| 0   NVIDIA GeForce ...   Off      | 00000000:07:00:0 |      0%      Default |
| 30%   34C   P0      N/A / 320W  |  0MiB / 10240MiB |           | MIG M. |
+-----+-----+-----+

Processes:
GPU  GI  CI      PID  Type  Process name          GPU Memory
ID   ID   ID
-----
No running processes found
```

- Step 14. 如果不使用该资源后，需要进行释放，以免花费额外的费用



2.5 阿里云


阿里云GPU服务器租用价格表包括包年包月价格、一个小时收费以及学生GPU服务器租用费用，阿里云GPU计算卡包括NVIDIA V100计算卡、T4计算卡、A10计算卡和A100计算卡，分为多种实例规格，如NVIDIA V100 GPU卡的GPU云服务器gn6v实例、GPU云服务器gn6i采用T4计算卡、GPU云服务器gn7e实例采用A100计算卡、GPU云服务器gn7i实例采用A10计算卡。GPU云服务器规格不同、CPU内存配置不同价格也不同。

整体来说，服务器价格对于学生和个人来说小贵，更多的是面向企业用户。

- Step 1.先进入阿里云官网，登陆账户：<https://cn.aliyun.com/>



- Step 2.在产品-计算中，找到GPU云服务器入口



- Step 3. 阿里云提供了V100、T4、A10、P4、P100 共计5种显卡配置的GPU云服务器，其中如果涉及训练和科学计算的，一定要选择V100。



- Step 4. 根据个人需求选择配置和操作系统。



通过对比也可以看到，云服务厂商的 GPU 服务器对大多数人来说都是租不起的，阿里云或 AWS 的 GPU 实例价格大家都知道的。很多学生或者自由职业者想自己做做ML和DL的同学都苦于没有廉价的平台来做实验。GPU租赁市场很乱，大家一定要记得去甄别一些，所谓的“免费”！有些打折免费的口号，根本没有机器去选择，最后引导还是会指向用户去选择更贵的机器，所以拥有个性化推荐的平台是非常有优势的，根据个人的项目情况选择最具性价比的机器，避免算力浪费的同时也降低了用户的使用成本，这样的循环才是好的。站在消费者的角度来看，我觉得大家不是为了选择便宜而去选择，从接受一个新平台来说，如果有一种物超所值的感受，那么价格绝对就不是某个平台的核心竞争力，保证流畅/效率/安全，才是对一个开发者而言最重要的。